Diseño e Implementación de un Asistente Virtual para Tiendas de Ropa mediante un Pipeline de NLP.

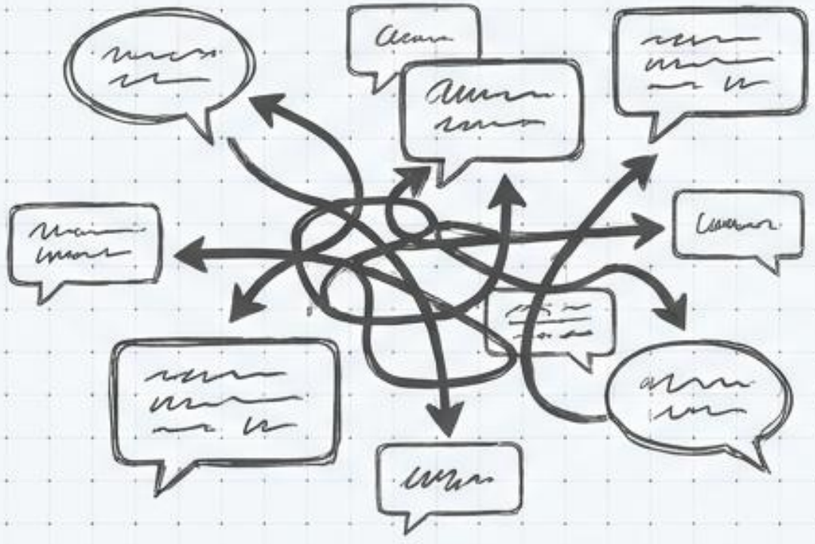
Comparación de Modelos de Clasificación, Adaptación al Dominio y Despliegue.

Materia: Tópicos Avanzados de Programación (ELEC103)	Universidad: UAGRM | Semestre: 2-2026
Docente: MSc. Ing. Kawaida Villegas Kenji	Equipo de Ingeniería: Aranibar C., Calani F., Gonzales R., Rojas J.

Gemini Notebook

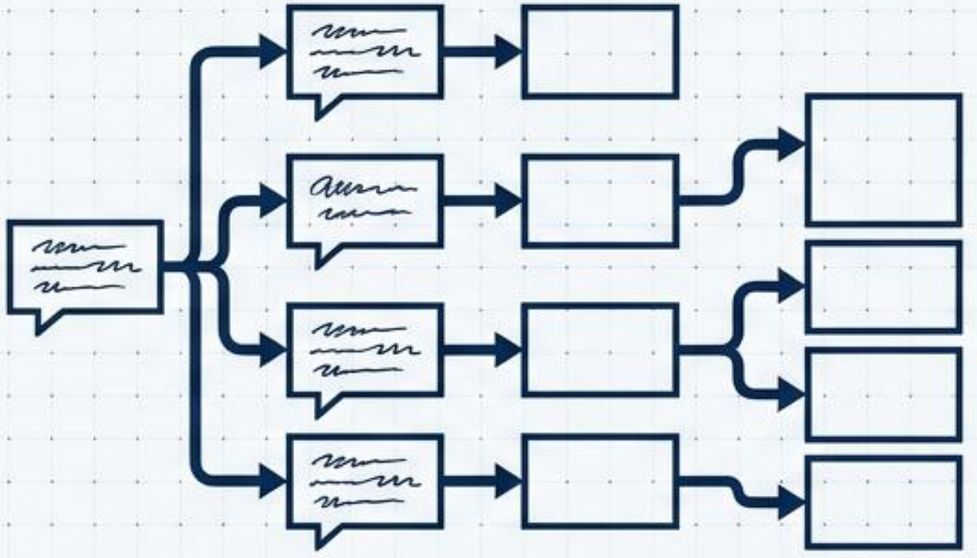
DE CONSULTAS CAÓTICAS A ENRUTAMIENTO ESTRUCTURADO

El Problema



Saturación operativa por consultas repetitivas de clientes (tallas, envíos) y administración (ventas, inventario).

El Sistema



Clasificación supervisada de texto en 14 intenciones específicas del dominio textil.

REGLA ESTRICTA DE PRODUCCIÓN: Umbral de confianza mínimo del 0.60. Las predicciones inferiores disparan un fallback (“no entendí”) garantizando cero alucinaciones.

Gemini Notebook

Arquitectura de Datos y Entornos de Entrenamiento

Pilar 1: Dataset Principal (Dominio)

- 1.120 frases etiquetadas (oct/nov 2026).
- Equilibrio perfecto: 14 clases × 80 frases/clase.
- División estricta 80/20 (Semilla 42).

Pilar 2: Datasets Complementarios (OOD & Calibración)

- ~31.000 filas de Amazon MASSIVE y Bitext Customer Support.
- Uso: Calibración de consultas reales y entrenamiento del detector fuera de dominio (OOD).

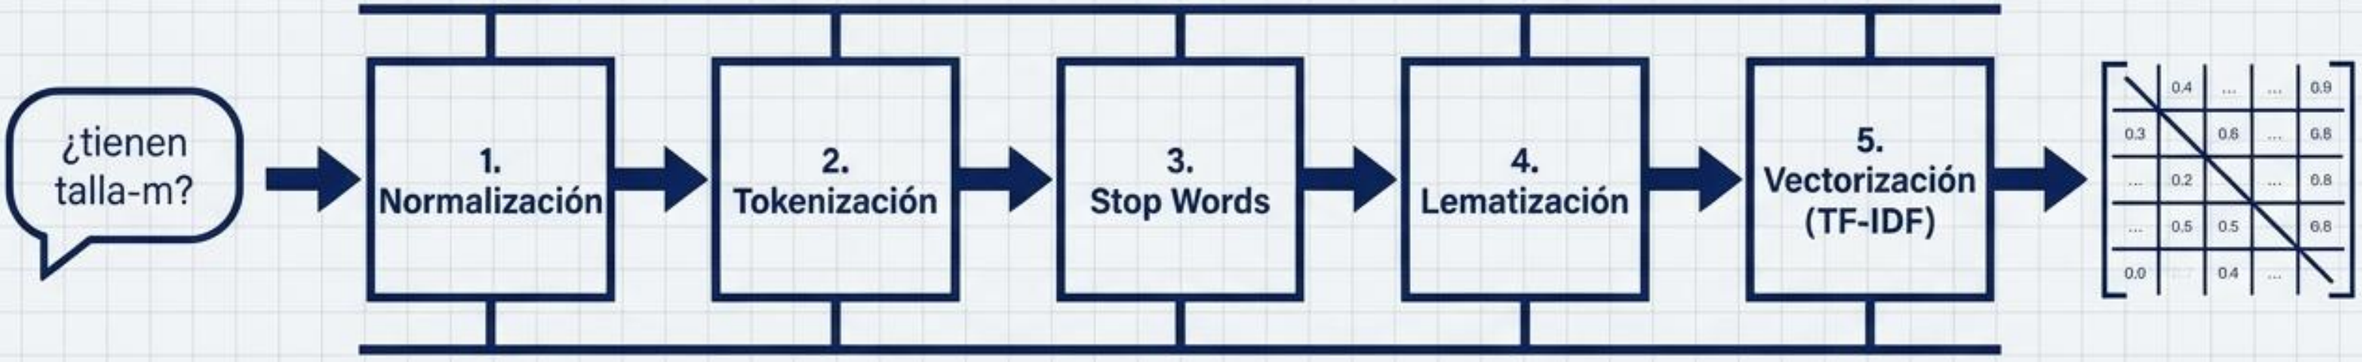
Pilar 3: Inventario y Simulación (Entorno)

- Amazon Fashion: 8.000 productos y 15.000 ventas simuladas.
- Uso: Población de la base de datos para respuestas reales de la API.



Gemini Notebook

Flujo de Transformación Lingüística Extremo a Extremo



Principio DRY (Don't Repeat Yourself): Centralizado en TextPreprocessor. El backend y la API consumen la misma clase que el entorno de entrenamiento. El **preprocesamiento nunca se reimplementa.**

Gemini Notebook

Fases 1 & 2: Ingeniería Lingüística Específica del Dominio

Fase 1: Normalización Estratégica

Decisión: Conservar números, decimales y guiones en formatos clave.

Justificación: En retail, los números son atributos críticos (precios, tallas).



Fase 2: Tokenización por Expresiones Regulares

Decisión: Uso de Regex propio frente a split() tradicional.

Justificación: Permite separar magnitudes y unidades sin perder el contexto.



Gemini Notebook

Fases 3 & 4: Optimización Radical del Vocabulario

Stop Words Personalizadas (El Gran Salto)

+8.5 puntos F1 macro (0.756 → 0.841)

- **Decisión**: Descartar lista por defecto de spaCy. Retención de 35 palabras vitales (“cuánto”, “hay”, “tienen”) y adición de muletillas de chat (“porfa”, “oye”).
- **Impacto**: Mejora radical en detección de inventario (consultar_stock).

Lematización vs Stemming



- **Decisión**: Lematización (spaCy es_core_news_sm) + correcciones custom (“hola” → “holar”).
- **Justificación (Empate Técnico):** F1 0.841 (Lema) vs 0.844 (Stem).
- Se elige Lema priorizando la interpretabilidad (palabras legibles en la UI del frontend).

Gemini Notebook

Fase 5: Vectorización TF-IDF y Captura de Contexto

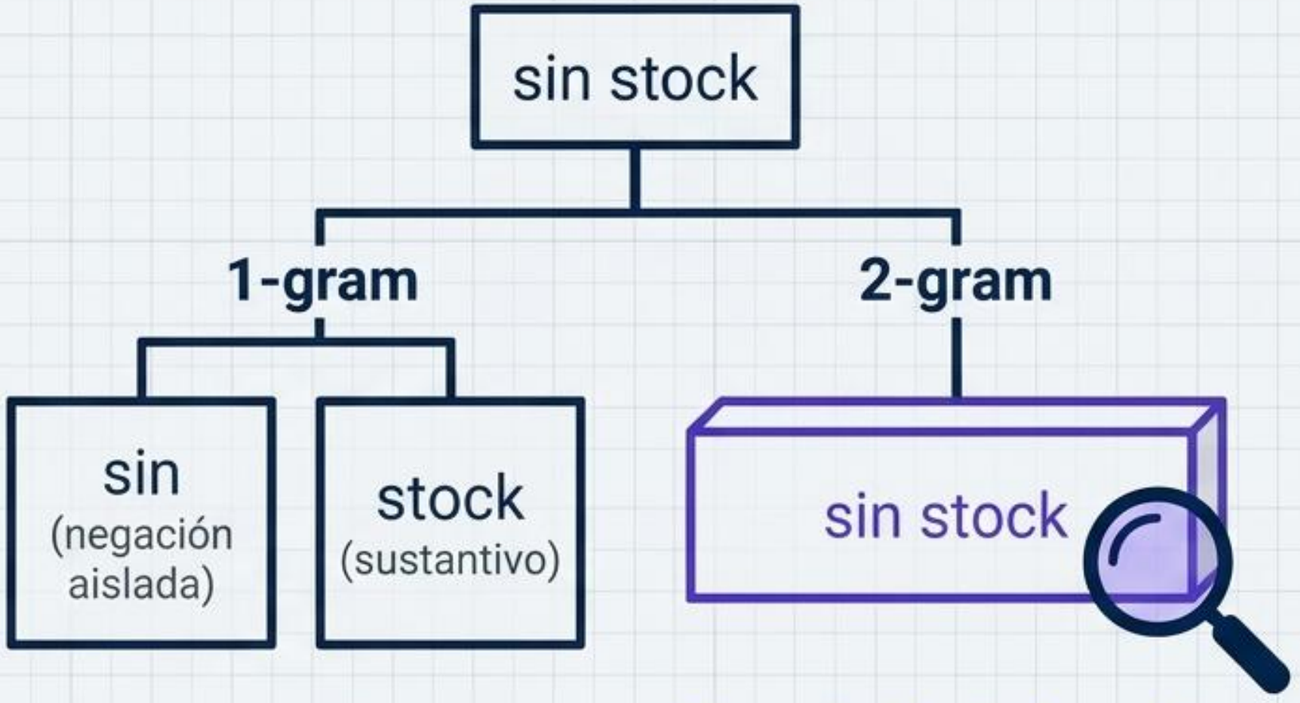
Configuración Técnica y Justificación

- Parámetros: **ngram_range**(1, 2), **min_df=1**, **max_df=0.95**, **sublinear_tf=True**.

- Los unigramas **pierden dependencias críticas**.

- Los bigramas logran **capturar** la **semántica compuesta inherente a las ventas**.

N-Gram Extraction Diagram



Resultado: Sentido ambiguo

Resultado: Intención inequívoca capturada

Gemini Notebook

Matriz de Rendimiento: Evaluación Empírica de Modelos

Modelo	Exactitud	F1 Prueba	F1 Validación Cruzada
Línea Base (Clase más frecuente)	7.1%	0.009	N/A
Naive Bayes (ComplementNB)	77.7%	0.774	0.801
Regresión Logística **(En** Producción)	**81.7%**	**0.818**	**0.841**

Hiperparámetros óptimos **(GridSearchCv)**: **C = 10.0, class_weight = balanced**. Validación cruzada estratificada de 5 particiones.

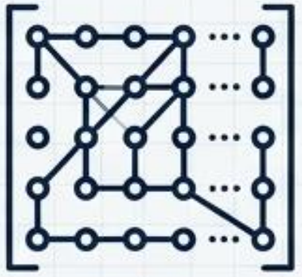
Gemini Notebook

Justificación de Arquitectura: Por qué Regresión Logística



1. Rendimiento Sólido

Supera a Naive Bayes por **~4 puntos** en datos de prueba.



2. Adecuación Matemática

Manejo superior de alta dimensionalidad y matrices dispersas generadas por la vectorización TF-IDF.



3. Calibración Probabilística

Entrega probabilidades precisas, permitiendo establecer el umbral exacto de **0.60** para mitigar alucinaciones. NB empuja probabilidades a los extremos.



4. Interpretabilidad Blanca

Los 'pesos' asignados permiten extraer qué términos empujan cada intención en tiempo real para auditar el modelo en el frontend.

Gemini Notebook

Análisis Clínico de Errores y Solapamiento Semántico

Rendimiento Máximo:

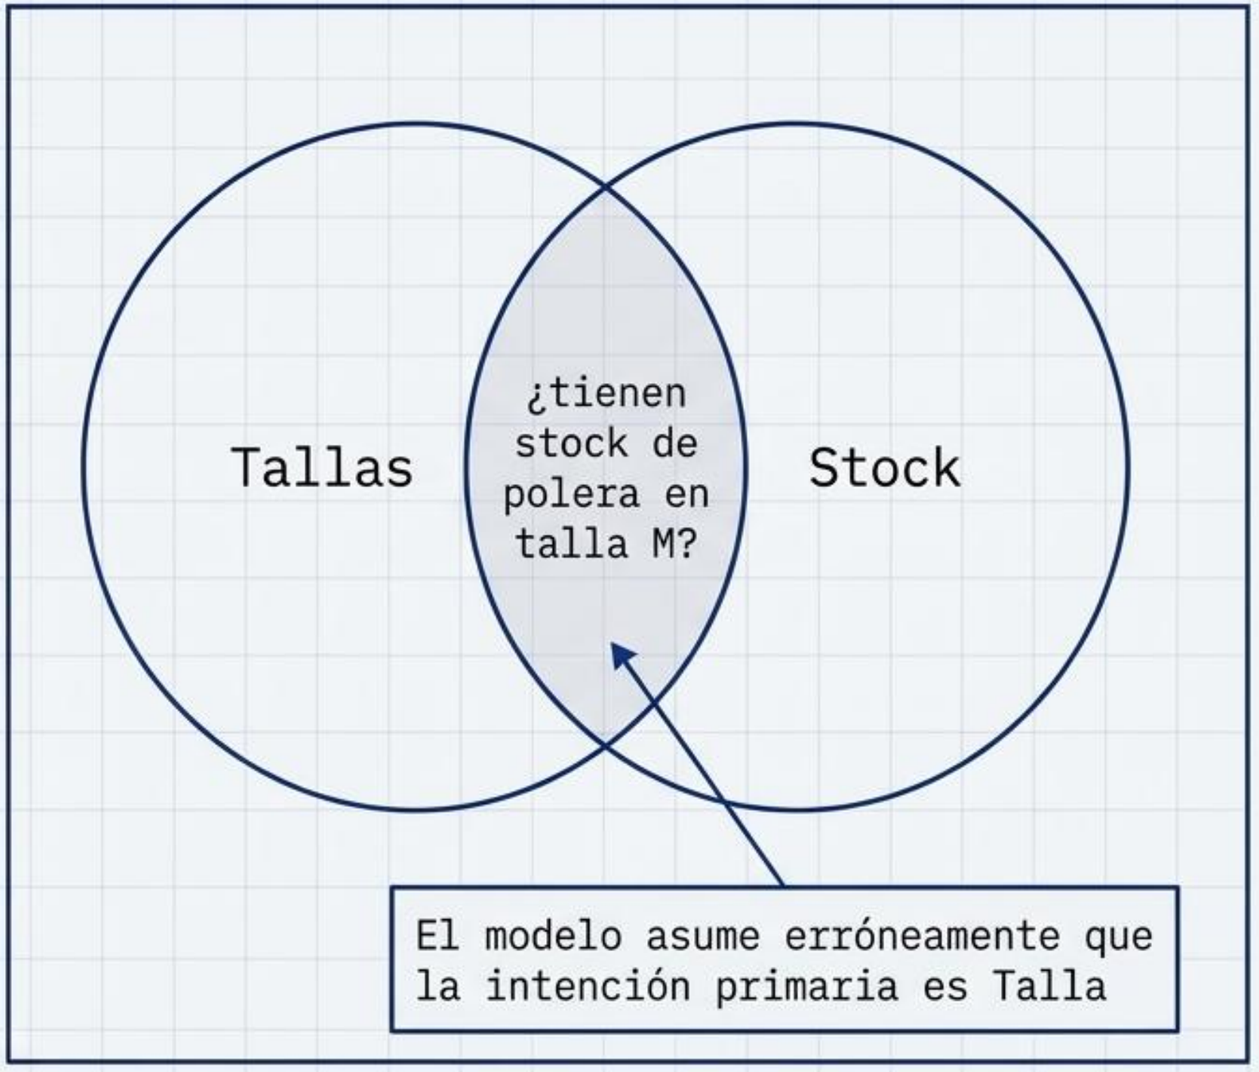
- metodos_pago y saludo (**F1 > 0.90**) - Patrones léxicos muy definidos.

Zonas de Confusión:

- consultar_stock (**0.71**) vs consultar_tallas (**0.72**).

Diagnóstico y Solución:

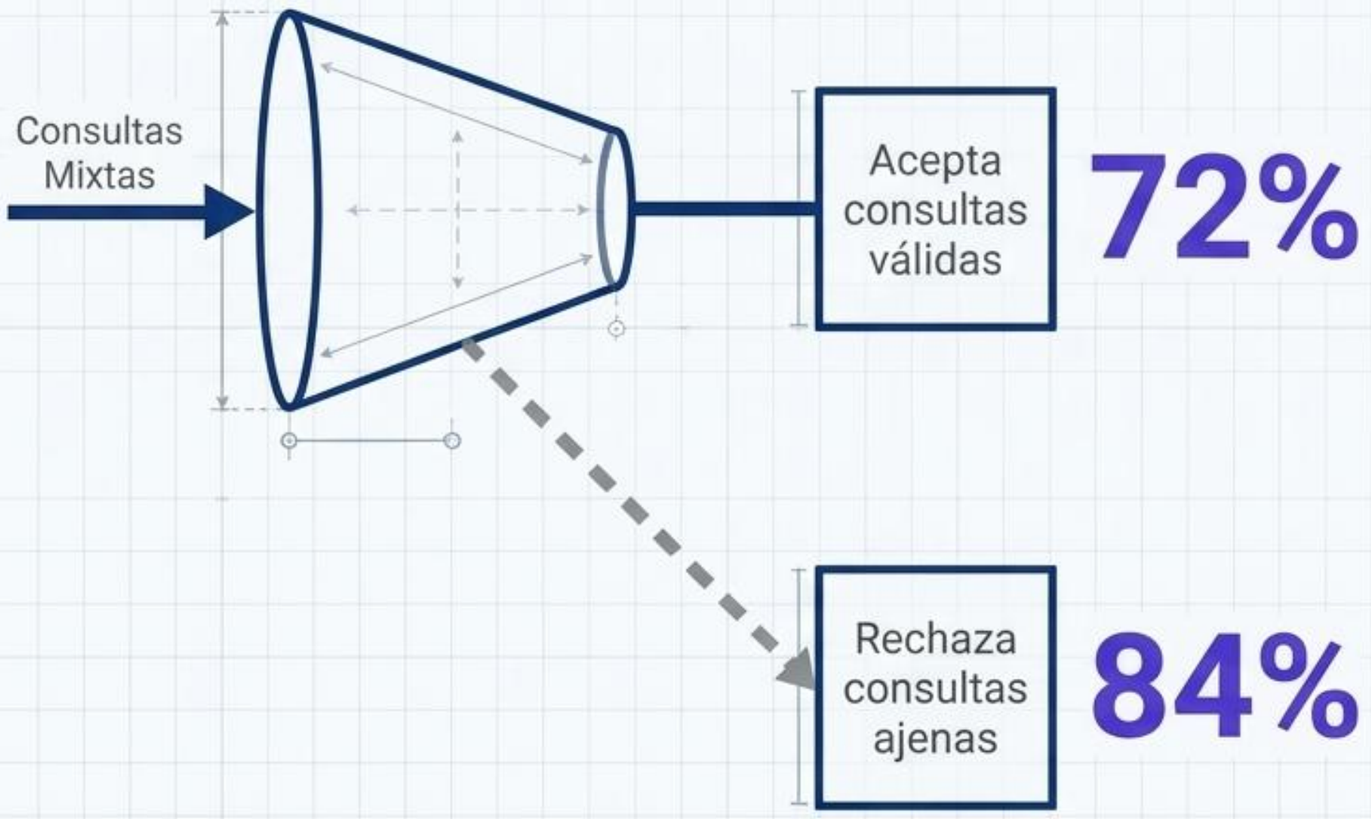
- La palabra 'talla' tiene un peso probabilístico mayor que 'stock'.
- Solución: Rebalanceo de frases inyectando menciones de tallas en las consultas de stock.



Gemini Notebook

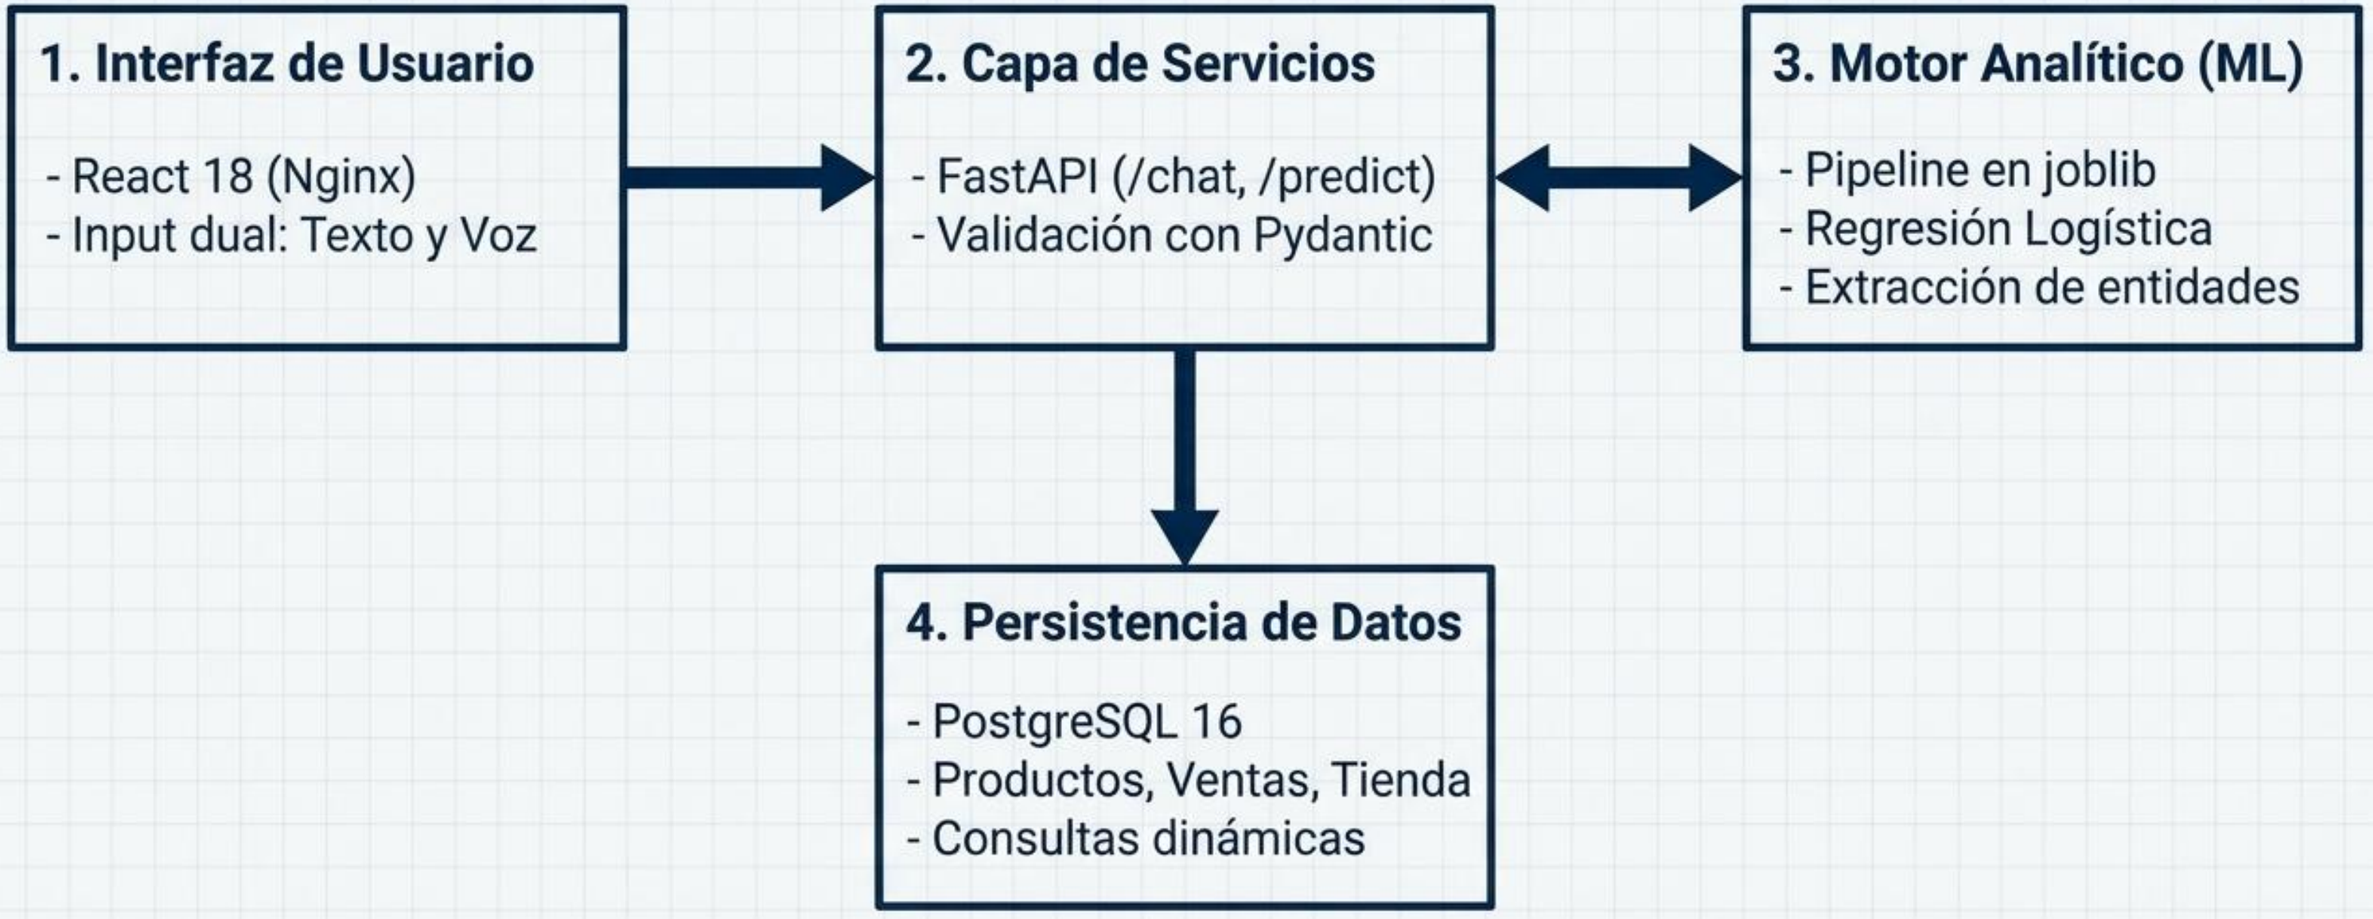
Robustez del Sistema: Detector Fuera de Dominio (OOD)

- **El Desafío**: Consultas ajenas al dominio textil que engañan la distribución de probabilidad de las 14 clases.
- **Implementación:** Clasificador OOD paralelo calibrado con 1.000 consultas reales del dataset MASSIVE/Bitext.
- **Estado:** Módulo validado (src/models/ood.py), pendiente de integración final al endpoint /chat.



Gemini Notebook

Arquitectura del Sistema (Flujo Extremo a Extremo)



Gemini Notebook

Fiabilidad del Sistema y Validaciones de API

Control de Estado HTTP (API)

- **HTTP 422:** Bloqueo de payloads inválidos (textos vacíos o > 500 caracteres).
- **HTTP 400:** Rechazo de formatos de archivo incorrectos en importación.
- **Filtro de Idioma:** Validación exclusiva para inputs en español.

Cobertura de Pruebas Automatizadas

- **136** pruebas automatizadas escritas en pytest.
- Validación exhaustiva de las **5** fases del pipeline NLP.
- Pruebas de integración para endpoints de inventario y respuestas del bot.

Gemini Notebook

Balance del Proyecto y Trabajo Futuro

Limitaciones Actuales

- **Dependencia Sintética**: **88%** del dataset generado vía IA; datos reales (Bitext) limitados a **3** intenciones.
- **Sensibilidad Muestral**: Con **80** frases por clase, el **F1** varía según la partición específica.
- **Inventario Simulado**: Tallas no mapeadas dinámicamente. OOD pendiente de conexión en **/chat**.

Logros del Sistema

- **Solución Integral**: Sistema NLP ligero y adaptado al dominio, sin depender de **LLMs** externos de alto costo.
- **Transparencia**: Modelo altamente interpretable que justifica sus predicciones en el frontend.
- **Despliegue Profesional**: Arquitectura contenerizada lista para producción y sólida prevención de alucinaciones (**umbral 0.60**).

Gemini Notebook